

Содержание

Приложение А. План обеспечения данными	1
А.1. Назначение документа	1
А.2. Принцип разделения	1
А.3. Реестр источников данных	2
А.4. Прайс-листы: реальный контейнер, синтетическое значение	5
А.5. Методика генерации синтетических данных	6
А.6. Обезличивание обращений покупателей	7
А.7. Вопросы к Заказчику (чек-лист интервью)	7
А.8. Трассировка “источник - требование”	9
А.9. Режим обращения с данными	9
А.10. Порядок применения	10

Приложение А. План обеспечения данными

Приложение А. План обеспечения данными

К документу: Бизнес-функциональные требования (БФТ), версия 1.0

Проект: Корпоративная платформа товарных знаний на базе мультимодального GraphRAG

Заказчик: ООО “Скейлкар” (scalecar.ru)

Версия: 1.0 Статус: Черновик / на согласовании с Заказчиком

Дата: 11 августа 2026 г.

А.1. Назначение документа

Документ определяет, какие данные проекта берутся из реальных источников Заказчика, какие замещаются синтетическими, и на каком основании принято каждое решение. Он же фиксирует перечень вопросов к Заказчику, ответы на которые влияют на архитектуру, а не на наполнение системы.

Документ решает три задачи: обосновать достоверность результатов приёмки, ограничить объём чувствительных данных, покидающих контур Заказчика, и защитить проект от типовой ошибки - демонстрации качества на искусственно чистом наборе.

А.2. Принцип разделения

В основу положено следующее правило:

Реальными берутся данные, которые система анализирует. Синтетическими замещаются данные, которые система защищает.

Обоснование. Риск качества сосредоточен в наименованиях, каталогах, прайсах и изображениях: именно их разбирает конвейер извлечения, и именно там синтетический набор подменяет результат - модель показывает высокую точность на искусственно однородных данных и теряет её на продуктиве.

Закупочные цены, договоры и персональные данные система не анализирует: она закрывает их грифом и обязана не выдать их пользователю без прав. Для проверки этого механизма содержимое узла безразлично - значение имеет только корректность метки и работа фильтрации на этапе выборки. Следовательно, реальные значения не дают выигрыша в достоверности приёмки, но создают риск раскрытия при публичной защите.

Из правила есть одно исключение - прайс-листы поставщиков, которые одновременно анализируются и подлежат защите. Порядок работы с ними описан в разделе А.4.

А.3. Реестр источников данных

ID	Домен данных	Режим	Объём для PoC	Обоснование выбора режима
D-01	Карточки товаров: наименование, масштаб, производитель, категория, атрибуты	Реальные (публичные)	2 000-3 000 SKU в 3-4 категориях	Главный риск проекта - разрешение сущностей. Реальные наименования содержат смесь языков, номера экипажей, имена пилотов, скобки и вариативное написание марок. Синтетический набор будет стерильным: парсер покажет высокую точность на нём и провалится на продуктиве
D-02	Фотографии моделей и упаковок	Реальные (публичные)	1 фото на SKU плюс 50 намеренно сложных: блики, нестандартный ракурс, фон	Проверяется поиск по изображению (FR-2.5). Сгенерированные или студийно-чистые изображения не воспроизводят реальную вариативность и делают оценку качества недостоверной

ID	Домен данных	Режим	Объём для PoC	Обоснование выбора режима
D-03	PDF-каталоги производителей моделей, журнальные серии	Реальные	3-5 каталогов разных издателей	Источник связи “модель - прототип - тираж”. Разная вёрстка у разных производителей - существенная часть сложности задачи извлечения
D-04	Прайс-листы поставщиков	Гибрид: реальный файл, синтетическая цена	5 файлов намеренно разного качества, включая один скан низкого разрешения	Риск R-05 полностью сосредоточен в разнокачественности исходников. Чистый сгенерированный PDF подтвердит лишь заведомо известное. При этом закупочная цена - коммерческая тайна, поэтому подменяется при индексации
D-05	Закупочные цены, маржинальность	Синтетика	На весь набор D-01	Объект защиты, а не объект анализа. Для проверки разграничения доступа (FR-3.1, FR-3.2) содержимое узла безразлично - значение имеет только присвоенный гриф. Реальные цифры на публичной защите создают риск без выигрыша в качестве

ID	Домен данных	Режим	Объём для PoC	Обоснование выбора режима
D-06	Договоры поставки, эксклюзивные соглашения, планы поставок	Синтетика по публичному шаблону	5-7 документов объёмом 8-15 страниц	Требуется реалистичный формат - многостраничный документ с реквизитами, приложениями и спецификацией, - чтобы проверить чанкинг длинных документов и наследование грифа. Содержание при этом значения не имеет
D-07	Персональные данные клиентов, история заказов	Синтетика	500 клиентов, 2 000 заказов	Требование 152-ФЗ. Дополнительно синтетика удобнее для тестирования PII-фильтра: известен эталон, поддаётся точному расчёту полнота обнаружения
D-08	Учётные записи и роли	Синтетика	5 пользователей по одному на роль	Интеграция с реальным каталогом пользователей не проверяет ни одной архитектурной гипотезы. Требуется знать модель ролей, но не сами учётные записи

ID	Домен данных	Режим	Объём для PoC	Обоснование выбора режима
D-09	Остатки, наличие, сроки поставки	Мок API с управляемой задержкой	Генератор на 100 % набора D-01	BR-03 - требование к свежести данных, а не к их содержимому. Мок позволяет воспроизвести протухание данных и проверить корректность деградации, чего реальный источник не даст
D-10	Обращения покупателей: чат, электронная почта, поисковые запросы по сайту	Реальные, обезличенные	200-300 обращений	Основа регрессионного набора (FR-4.3) и приоритизации сценариев. Придуманные вопросы отражают представления исполнителя о коллекционерах, а не их фактические запросы. Коммерческой тайны практически не содержат
D-11	Профиль нагрузки: посетители в сутки, суточный график, пиковые часы	Реальные агрегаты (веб-аналитика)	Помесячно за 3 месяца	Вход для расчёта ресурсов (NFR-1) и обоснования стоимости владения. Требуются агрегированные показатели, а не журналы обращений

А.4. Прайс-листы: реальный контейнер, синтетическое значение

Прайс-лист - единственный источник, который одновременно является объектом анализа и носителем коммерческой тайны. Разделение выполняется по полям, а не по файлам:

- От Заказчика запрашиваются подлинные файлы поставщиков без изменения вёрстки,

включая экземпляры плохого качества. Сохраняются структура таблиц, колонтитулы, сноски, опечатки и артефакты сканирования - то есть всё, что нагружает конвейер извлечения. - Колонка закупочной цены замещается синтетическим значением на этапе индексации, до записи в хранилище. Подмена выполняется отдельным шагом конвейера, факт подмены фиксируется в метаданных документа. - Оценка качества извлечения при этом не страдает: проверяется способность конвейера найти и распарсить ячейку в её реальном окружении, а не корректность самого числа.

Альтернативный вариант, если Заказчик готов: запросить у поставщиков прайсы с уже удалённой ценовой колонкой. Он проще организационно, но хуже с точки зрения проверки, поскольку меняет верстку таблицы.

А.5. Методика генерации синтетических данных

Синтетика должна воспроизводить статистическую форму реальных данных, а не только их формат. Набор, где все закупочные цены составляют ровно 60 % от розничной, не проверяет ни ранжирование, ни выявление аномалий.

Поле	Метод генерации	Контроль правдоподобия
Закупочная цена	Розничная цена $\times$ (1 - маржа), где маржа выбирается из распределения, заданного по группе брендов	Заказчик подтверждает диапазон маржи по группам, не раскрывая значений по конкретным позициям
Срок поставки	Логнормальное распределение с параметрами по типу поставщика: отечественный, импортный, предзаказ	Медиана и хвост согласуются с фактическими сроками, названными заказчиком устно
Договоры	Публичный шаблон договора поставки, заполненный вымышленными реквизитами; спецификация формируется из реальных артикулов D-01	Проверяется объём, структура разделов и наличие приложений - то, что влияет на чанкинг
ПДн клиентов	Библиотека генерации тестовых данных с русской локалью: ФИО, телефон, адрес, электронная почта	Формат должен совпадать с реальным, включая типичные ошибки ввода: пробелы в номере, кириллица в латинском адресе
История заказов	Случайная выборка из D-01 с распределением по частоте, воспроизводящим долгий хвост каталога	Распределение сверяется с агрегатами D-11
Остатки	Генератор с управляемым лагом обновления и долей позиций "под заказ"	Доля позиций в наличии соответствует публичной статистике сайта

Правдоподобие набора подтверждается Заказчиком на уровне диапазонов и распределений. Такая формулировка позволяет получить подтверждение, не раскрывая значений по конкретным позициям и контрагентам.

А.6. Обезличивание обращений покупателей

Источник D-10 наиболее ценен для проекта и требует отдельной процедуры, поскольку содержит и полезное содержание, и персональные данные. - Из выгрузки удаляются идентификаторы клиента, номера заказов, контактные данные и подписи. Обработка выполняется в контуре Заказчика до передачи исполнителю. - Сохраняются формулировки вопроса, упоминания артикулов и наименований, а также признак эскалации и итог обращения - то, ради чего набор и запрашивается. - Результат вычитывается вручную. Автоматическая маскировка на выборке такого объёма не даёт достаточной гарантии, а объём в 200-300 обращений допускает сплошную проверку. - Из полученного набора формируется регрессионный комплект: не менее 50 вопросов с эталонными фактами, подтверждёнными экспертом-товароведом.

А.7. Вопросы к Заказчику (чек-лист интервью)

Перечисленное ниже - запрос ответов, а не данных. Каждый пункт влияет на архитектурное решение, и цена позднего выяснения существенно выше стоимости самого вопроса.

ID	Вопрос к заказчику	Что меняется в решении в зависимости от ответа
Q-01	Существует ли API остатков? Какой протокол, какая фактическая периодичность обновления?	При отсутствии API правило BR-03 в текущей формулировке невыполнимо: переходим на файловый обмен по расписанию и перепишем правило на актуальность "на утро текущего дня". Меняется диаграмма последовательности и состав контейнеров
Q-02	Может ли сайт передавать идентификатор и роль пользователя в запрос к виджету ассистента?	Это основание всей модели разграничения доступа. При отрицательном ответе требуется собственная аутентификация во внутреннем контуре и вторая интеграция - реализация риска R-06 и расширение объёма работ
Q-03	Сколько ролей фактически заведено в административной панели? Пересекаются ли их права? Есть ли личный кабинет поставщика?	Модель из пяти ролей и трёх грифов - гипотеза исполнителя. При большем числе ролей с пересекающимися правами ролевая модель на узлах усложняется, и может потребоваться переход к атрибутивной модели доступа

ID	Вопрос к заказчику	Что меняется в решении в зависимости от ответа
Q-04	Каким каналом поступают прайс-листы поставщиков: электронная почта, личный кабинет, учётная система, мессенджер? Кто разбирает их сейчас?	Определяет точку входа конвейера загрузки (FR-1.1) и наличие обязательного ручного шага. Влияет на оценку трудоёмкости этапа MVP
Q-05	В каком виде сейчас зафиксирована связь “модель - прототип”: отдельное поле, тег, только текст описания?	Определяет объём холодного старта графа. Если связь существует только в тексте описания, весь слой Prototype строится извлечением, и риск R-02 возрастает кратно вместе с потребностью в часах эксперта
Q-06	Подтвердите порядок величин: время подготовки ответа менеджером, время заведения позиции, доля вопросов, эскалируемых к более опытному сотруднику	Без подтверждения раздел 1.2 БФТ и всё экономическое обоснование остаются недоказуемыми на защите
Q-07	Какие вопросы покупателей чаще всего остаются без корректного ответа или требуют эскалации?	Прямой вход в регрессионный набор и в приоритизацию требований уровня Must. Позволяет отсеять сценарии, интересные технически, но не нужные бизнесу
Q-08	Готов ли заказчик выделить эксперта-товароведа и в объёме скольких часов?	Допущение раздела 6.2 БФТ. Без эксперта невозможно подтвердить правила слияния сущностей (FR-1.4) и принять качество ответов
Q-09	Есть ли ограничения на публикацию: допустимо ли показывать наименования, фотографии и названия поставщиков в демонстрационном видео и в репозитории проекта?	Определяет содержание демонстрации. Вопрос следует закрыть до записи видео, а не после
Q-10	Допустима ли разовая обработка обезличенного набора на арендованном внешнем GPU?	При отрицательном ответе профиль B (NFR-1) недоступен, нагрузочный отчёт снимается на полностью синтетическом наборе, и это ограничение необходимо явно оговорить в отчёте

ID	Вопрос к заказчику	Что меняется в решении в зависимости от ответа
Q-11	Кто со стороны заказчика принимает решение о приёме качества ответов и по каким критериям?	Без назначенного лица приёмка качества генеративного компонента превращается в спор о вкусе. Критерии фиксируются как NFR-4

А.8. Трассировка “источник - требование”

Таблица служит двум целям: подтвердить, что запрашиваемые у Заказчика данные не избыточны, и показать, какие требования окажутся непроверяемыми при отказе в предоставлении конкретного источника.

Источник	Требования, которые он покрывает	Что не будет проверено без него
D-01, D-03	FR-1.3, FR-1.4, FR-1.5, FR-2.1, FR-2.7	Качество построения графа и многошаговые запросы - то есть основная гипотеза проекта
D-02	FR-1.2, FR-2.5	Мультимодальный сценарий целиком
D-04	FR-1.1, FR-1.7, FR-2.8	Устойчивость конвейера извлечения к реальному качеству исходников (риск R-05)
D-05, D-06	FR-1.6, FR-3.1, FR-3.2, FR-3.4, BR-01, BR-02	Разграничение доступа и защита от утечки - блокирующий критерий приёма
D-07	FR-3.3, FR-3.4, BR-06	Полнота фильтрации персональных данных на входе и выходе
D-08	FR-3.1, FR-3.2, FR-3.5	Сценарий “один документ - разный ответ для разных ролей”
D-09	BR-02, BR-03, FR-2.7	Корректность деградации при устаревших данных
D-10	FR-4.3, FR-4.4, NFR-4	Объективная оценка качества ответов
D-11	NFR-1, NFR-3, раздел FinOps	Обоснованность расчёта ресурсов и стоимости владения

А.9. Режим обращения с данными

А.9.1. Ограничения (обязательны к исполнению)

- Реальные персональные данные, реальные закупочные цены и подлинные тексты договоров не попадают в репозиторий проекта ни в каком виде, включая тестовые фикстуры, примеры в документации, снимки экрана и кэш промежуточных артефактов.
- Репозиторий передаётся преподавателю и остаётся в портфолио на неопределённый срок. Любые данные в нём следует считать опубликованными.

- Обработка данных выполняется в закрытом контуре. Передача содержимого во внешние сервисы, включая сервисы распознавания и перевода, исключена.
- При аренде внешнего GPU (профиль В по NFR-1) на арендованный узел передаётся только обезличенный либо синтетический набор, и только при положительном ответе на вопрос Q-10.

А.9.2. Организация хранения

- Наборы данных разделяются на два каталога: реальные данные и синтетические. Каталог реальных данных целиком исключается из системы контроля версий.
- В репозиторий помещаются генераторы синтетики и схемы данных, но не сами наборы. Это обеспечивает воспроизводимость без переноса содержимого.
- Каждый набор сопровождается паспортом: источник, дата получения, режим по настоящему приложению, применённые преобразования, срок хранения.
- Демонстрационное видео записывается на наборе, прошедшем проверку по вопросу Q-09.

А.10. Порядок применения

- До начала PoC: провести интервью по разделу А.7, получить источники D-01, D-02, D-04 и D-10, зафиксировать ответы в протоколе и при необходимости выпустить версию 1.1 настоящего приложения.
- На этапе PoC: подтвердить на источниках D-01 и D-04 наиболее рискованные требования - FR-1.4 и FR-3.1, а также жизнеспособность профиля А по NFR-1.
- На этапе MVP: расширить набор до полного объёма каталога, сформировать регрессионный комплект из D-10.
- Перед защитой: сверить состав демонстрационного набора с разделом А.9 и подтвердить отсутствие чувствительных данных в репозитории.