

Стратегия внедрения, оценка рисков и дорожная карта AI-проекта

Платформа товарных знаний на базе мультимодального GraphRAG

Домашнее задание 1. Курс OTUS “ИИ-архитектор”

Содержание

Контекст	1
1. Уточняющие вопросы	2
2. Контрактная модель	2
Уровень неопределённости	2
Выбор: гибрид	2
Откуда взялся потолок	3
Почему это выгодно обеим сторонам	3
3. Карта рисков	4
Матрица	4
Реестр: оценка	4
Реестр: реагирование	5
Риски, закрытые договором	8
4. Дорожная карта	8
Критерии готовности (DoD)	8
Документы проекта	10

Контекст

Репозиторий проекта: https://github.com/SandalAndrey/otus_ai_architect

Заказчик - интернет-магазин коллекционных масштабных моделей: более 15 000 позиций в наличии, около 400 автомобильных марок, порядка 600 производителей моделей. Доставка по всей России.

Задача. Знания о товаре рассредоточены между карточками сайта, PDF-каталогами производителей, прайсами поставщиков, сканами упаковки и опытом отдельных сотрудников. Отсюда три измеримые потери: менеджер тратит 4-6 минут на нетривиальный товарный вопрос, заведение позиции из прайса занимает около 12 минут, ошибки в атрибутах карточек ведут к возвратам.

Предлагается платформа интеллектуального доступа к товарным знаниям. Факты извлекаются обходом графа знаний, а не векторным поиском по тексту: запросы вида “что ещё выпускалось по этому прототипу” или “чем отличаются два выпуска” в плоском поиске не решаются в принципе.

Три ограничения, определяющие все дальнейшие решения:

1. Закрытый контур. Обращения к внешним LLM-API исключаются архитектурно.
2. Извлечение через граф знаний обязательно, векторного поиска недостаточно.
3. На этапе разработки доступен только CPU, GPU арендуется точно.

Ссылки на полные документы проекта приведены в конце.

1. Уточняющие вопросы

Отобраны шесть основных вопросов из двадцати ([План обеспечения данными и полный опросник](#)) по одному критерию: без ответа на эти вопросы нельзя стартовать проект, потому что ответ меняет архитектуру или основные расчеты.

Вопрос	Что меняется в решении
В каком виде сейчас зафиксирована связь “модель - прототип”: отдельное поле, тег или только текст описания?	Если только текст, весь слой прототипов строится извлечением. Наиболее вероятная причина выхода за потолок, ожидаемый вклад в резерв 37 ч
Может ли сайт передавать идентификатор и роль пользователя в запрос к платформе?	Основание всей модели разграничения доступа. При отрицательном ответе нужна собственная аутентификация и вторая интеграция
Есть ли требования по импортозамещению или наличию в реестре отечественного ПО?	Может исключить выбранные графовую и векторную базы. Выяснить после начала разработки означает переписывать слой хранения целиком
Кто создаёт золотой датасет из 50-100 пар вопрос-ответ, в какие сроки и в объёме скольких часов эксперта?	Датасет на критическом пути. Без него не измеримы метрики качества и невозможен переход к разработке
Существует ли API остатков? Какова фактическая периодичность обновления?	При отсутствии API правило о подтверждении наличия невыполнимо: переходим на суточную актуальность и меняем диаграмму последовательности
Есть ли собственные GPU и возможность закупки? Каков ожидаемый объём обращений в месяц?	Определяет профиль железа, выбор между арендой и покупкой и всю структуру стоимости владения

Вопросы о формате данных, объёме архива, площадке размещения и приёмке качества вынесены в полный опросник: они уточняют оценку, но не меняют решения.

2. Контрактная модель

Уровень неопределённости

Объём работ невозможно достоверно оценить до получения ответов на вопросы выше и до просмотра реальных прайс-листов: разброс трудоёмкости ключевого блока трёхкратный (120 / 180 / 320 ч). Это исключает твёрдую цену на весь проект.

Одновременно Заказчик - средний бизнес, реализующий первый проект такого класса, где бюджет утверждает владелец лично. Открытый почасовой счёт для него неприемлем.

Выбор: гибрид

Этап	Модель	Обоснование
Обследование и PoC, 6-8 недель	Fixed Price	Срок и объём жёстко ограничены, результат - отчёт и решение о продолжении, а не система. Твёрдая цена здесь возможна и снимает главное возражение при первом контакте. Этап снимает неопределённость, из-за которой FP непригоден дальше

Этап	Модель	Обоснование
Разработка MVP	T&M с потолком 1300 ч	Основной объём и основной источник разброса. Потолок даёт Заказчику предсказуемость, почасовой учёт защищает Исполнителя от трёхкратного разброса в блоке извлечения
Развитие и эксплуатация	T&M или абонентское обслуживание	Есть статистика фактических трудозатрат, доверие сформировано, потребность в потолке снижается

Единая модель на весь жизненный цикл избыточна: уровень неопределённости на этапах различается на порядок.

Откуда взялся потолок

Статья	Часы
Базовые работы, включая тестирование	736
Управление и надзор (тимлид, DS Lead, архитектор)	242
Резерв на риски	209
В смету, среднее	1187

Суммарная трудоёмкость получена имитацией на 200 000 испытаний с трёхточечными оценками и явно заданной корреляцией рисков качества данных. Распределение: P50 - 1181 ч, P80 - 1321 ч, P95 - 1446 ч.

Потолок 1300 ч изначально был установлен ровно на P80. После появления риска R-10 распределение сдвинулось вправо, и та же сумма стала соответствовать примерно P76. Потолок не поднимается: риск порождён проектным решением Исполнителя, а не изменением требований Заказчика.

Потолок должен покрывать типичное неблагоприятное развитие, но не одновременную реализацию всех рисков: последнее означает, что изменились условия проекта, а это предмет пересмотра объёма, а не оплаты Заказчиком.

Почему это выгодно обеим сторонам

Что получает Заказчик

Интерес	Как защищён
Знать верхнюю границу расхода до начала работ	Потолок на этап, выражен одной суммой
Не платить за ошибки Исполнителя	Твёрдая цена на обследование, где объём заранее известен
Возможность выйти из проекта	Право остановить работы на границе спринта с передачей результата
Видеть, куда уходят часы	Еженедельный отчёт, уведомление при 70 и 90 процентах потолка

Что получает Исполнитель

Интерес	Как защищён
Не работать бесплатно, если исходные данные окажутся хуже ожидаемого	Оплата по фактическим трудозатратам в пределах потолка
Пересмотр потолка при изменении объёма	Изменения только через запрос на изменение

Интерес	Как защищён
Не оплачивать простой по вине Заказчика	Непредоставление данных не расходует потолок
Стимул завершить проект досрочно	Половина сэкономленного объёма конвертируется в дополнительные работы

Конструкция сбалансирована в том смысле, что каждая сторона защищена от риска, которым не управляет. Заказчик не управляет трудоёмкостью распознавания прайсов; Исполнитель не управляет сроками и качеством предоставления данных.

Оговорка, без которой модель не работает. Т&М с потолком по умолчанию асимметричен: Заказчик защищён сверху, а Исполнитель не получает выгоды от экономии. Без условия о разделении экономии у него нет ни одного стимула завершить раньше срока, и модель вырождается в твёрдую цену с дополнительной отчётностью.

3. Карта рисков

Матрица

Границы уровней заданы по проекту: вероятность - по экспертной оценке срабатывания за время разработки, воздействие - по максимальной трёхточечной оценке ущерба в часах (низкое - до 50 ч, среднее - 50-100 ч, высокое - свыше 100 ч).

	Низкое воздействие	Среднее воздействие	Высокое воздействие
Низкая вероятность	R-07		
Средняя вероятность		R-04, R-05, R-06, R-09, R-10	R-03
Высокая вероятность		R-08	R-01, R-02

Зона высокого риска - светлая: R-01, R-02, R-03 относятся к качеству исходных данных и проверяются на этапе обследования, до принятия обязательства по потолку. R-08 качеством данных не лечится и остаётся постоянным.

Реестр: оценка

Ущерб указан трёхточечной оценкой в часах: минимум, ожидаемый, максимум.

ID	Риск	Категория	Вероятн	Ущерб, в часах	Уровень
R-01	Разрешение сущностей требует ручного подтверждения чаще, чем заложено	Данные	0.50	20 / 60 / 140	Высокий
R-02	Качество сканов и вёрстки прайсов ниже пригодного для автоматического разбора	Данные	0.45	20 / 50 / 120	Высокий
R-03	Связь модели с прототипом существует только в текстах описаний	Данные	0.40	40 / 80 / 160	Высокий
R-08	Модель добавляет в ответ характеристики, которых нет в извлечённом контексте	Качество AI	0.55	24 / 48 / 96	Высокий
R-09	Инъекция инструкций через наименование позиции в прайсе поставщика	Безопасность	0.30	16 / 32 / 64	Средний
R-04	Сайт не передаёт роль пользователя, нужна собственная аутентификация	Интеграция	0.30	30 / 60 / 100	Средний
R-06	Фильтрация по правам до извлечения снижает полноту выдачи	Архитектура	0.25	16 / 40 / 80	Средний
R-10	Мультиагентная схема не укладывается в бюджет латентности	Архитектура	0.40	16 / 32 / 72	Средний

ID	Риск	Категория	Вероятность	Ущерб,	Уровень
R-05	API остатков отсутствует, доступен только файловый обмен	Интеграция	0.85	16 / 32 / 60	Средний
R-07	Аренда внешнего GPU не согласована	Инфра	0.20	8 / 24 / 48	Низкий

Пояснения к двум рискам, специфика которых не видна из формулировки. R-01: одна и та же модель называется в источниках “BA3-2101”, “Жигули” и “Lada 1200”, а разные производители выпускают её по одной пресс-форме под своими артикулами. R-08: система дописывает несуществующий тираж или открывающиеся элементы, причём делает это уверенно и правдоподобно, поэтому ошибку замечает только специалист.

Реестр: реагирование

ID	Стратегия	Владелец	План митигации	Триггер
R-01	Mitigate	DS Lead	Порог уверенности и обязательное ручное подтверждение слияний ниже него. Часы эксперта-товароведа заложены в этап обследования	Более 30 % слияний ниже порога на выборке PoC
R-02	Mitigate	DS Lead	Проверка на пяти реальных прайсах разного качества до принятия обязательств. Ручная верификация закрепляется как штатная процедура, а не временная мера	Менее 70 % позиций разобрано
R-03	Mitigate	DS Lead	Ответ получаем до перехода к разработке. При срабатывании прототип сокращается до марки и года, детализация переносится в развитие	Отрицательный ответ на уточняющий вопрос

ID	Стратегия	Владелец	План митигации	Триггер
R-08	Mitigate	DS Lead	Ответ без ссылки на источник не отдаётся вовсе. При отсутствии подтверждающих узлов система отвечает “нет данных”, а не догадкой. Достоверность измеряется при каждом изменении промптов, схемы графа или модели	Faithfulness ниже 0.90 на золотом датасете
R-09	Mitigate	Backend	Содержимое документов считается недоверенным вводом наравне с полем поиска: фильтры применяются и на этапе индексации. Документы подаются в контекст структурировано, а не свободным текстом	Первое срабатывание на наборе атак
R-04	Transfer	Архитектор	Интеграция роли - зона ответственности Заказчика, закрыта условием договора. При невыполнении работы идут как изменение объёма	Отрицательный ответ на уточняющий вопрос

ID	Стратегия	Владелец	План митигации	Триггер
R-06	Mitigate	Архитектор	Проверка на выбранной векторной базе в PoC. При срабатывании расширяем выборку до фильтрации. Отказ от фильтрации до извлечения невозможен: это блокирующий критерий приёмки	Полнота падает более чем на 10 % при включении фильтра
R-10	Mitigate	Архитектор	Адаптивная маршрутизация: простые вопросы идут коротким путём в два вызова модели вместо пяти. Далее - сокращение входа переранжировщика и квантование	p95 выше 5 с на профиле В либо доля многошаговых вопросов выше 40 %
R-05	Accept	Архитектор	Правило о подтверждении наличия переформулирует под суточную актуальность	Отрицательный ответ на уточняющий вопрос
R-07	Accept	DevOps	Нагрузочный отчёт снимается на синтетическом наборе с явной оговоркой об ограничении	Отрицательный ответ на уточняющий вопрос

Владелец риска - не тот, кто выполняет работу по его устранению, а тот, кто отслеживает триггер и принимает решение о запуске плана. Разница существенна: несколько рисков имеют общий триггер (ответ Заказчика на уточняющий вопрос), но последствия у них разные, поэтому и владельцы разные. Риск без названного владельца остаётся незамеченным ровно до того момента, когда реагировать уже поздно.

Распределение неравномерно намеренно: четыре из десяти рисков относятся к качеству исходных данных и принадлежат DS Lead. Это отражает реальный профиль проекта, а не попытку раздать ответственность поровну.

Ожидаемый суммарный вклад: 209 ч, значение P95 - 376 ч. В смету заложен ожидаемый вклад, разницу покрывает потолок.

Риски, закрытые договором

Не закладываются в смету, поскольку относятся к зоне ответственности Заказчика: непредоставление источников в срок, невыделение эксперта-товароведа, расширение объема в ходе работ, медленный отклик учётной системы.

4. Дорожная карта

Допущение о команде: DS/ML один человек полной занятости, backend один, DevOps, QA и аналитик по половине ставки. При другом составе сроки пересчитываются, трудоёмкость не меняется.

Стадия	Неделя	Цель	Ключевые работы
Обследовать и PoC	8	Проверить три самых дорогих допущения и снять неопределённость	Интервью, доступ к данным, золотой датасет, разрешение сущностей на выборке, разбор реальных прайсов, проверка фильтрации по правам, замер на CPU
Decision Gate	8	Решение о продолжении	Продолжаем в объёме MVP, сокращаем объём с пересмотром потолка либо закрываем проект с оплатой сделанного
MVP	9-24	Работающая система на внутреннем контуре	Конвейер загрузки и построение графа, гибридный поиск, агент как конечный автомат, разграничение доступа и фильтры, интеграции, наблюдаемость, тестирование, нагрузочный отчёт
Production	25-34	Выход в публичный контур и масштабирование	Полный каталог, промышленное железо, омниканальность, мониторинг дрейфа качества, передача в поддержку

Ключевая особенность карты: **золотой датасет создаётся в первые недели**, а не перед приёмкой. Без него нечем измерять качество ни на PoC, ни на MVP, поэтому он лежит на критическом пути наравне с доступом к данным.

Критерии готовности (DoD)

PoC, неделя 8

Критерий	Порог
Золотой датасет создан и принят экспертом Заказчика	Не менее 50 пар вопрос-ответ
Разрешение сущностей на выборке каталога	Не менее 70 % слияний выше порога уверенности на 2000 позициях
Разбор реальных прайсов	Не менее 70 % позиций на пяти файлах разного качества
Фильтрация по правам выполняется до извлечения, а не постобработкой	Полнота выдачи падает не более чем на 10 %
Профиль CPU пригоден для демонстрации	Время до первого токена не более 8 с на p95
Оформлено решение Decision Gate с пересмотром потолка или без	Документ подписан обеими сторонами

Отрицательный результат по любому из первых четырёх пунктов - не провал, а основание пересмотреть объём до того, как в него вложены деньги.

MVP, неделя 24

Критерий	Порог
Требования уровня Must реализованы	Все
Достоверность ответов на золотом датасете	Faithfulness не менее 0.90
Релевантность ответов	Answer Relevancy не менее 0.85
Утечка данных ограниченного доступа пользователю без прав	0 случаев, блокирующий критерий
Каждый факт в ответе сопровождается ссылкой на источник	100 % ответов
Внутренний контур работает: менеджеры и закупщик пользуются системой	Не менее 20 сотрудников, месяц эксплуатации
Сквозная трассировка и аудит обращений	Доступны и демонстрируются на приёме
Нагрузочный отчёт снят	Время до первого токена не более 1.5 с, от 5 запросов в секунду

Блокирующий критерий проверяется отдельным тест-набором ролей: один и тот же документ должен давать ответ закупщику и отказ менеджеру, без раскрытия факта существования документа.

Production, неделя 34

Критерий	Порог
Публичный контур открыт на полном каталоге	15 000 позиций
Доступность в рабочее время подтверждена эксплуатацией	99.5 %, месяц наблюдения
Деградация при отказе сервиса инференса не роняет страницу	Переход на обычный поиск по каталогу
Доля типовых обращений, закрытых без оператора	Не менее 40 %
Мониторинг дрейфа качества	Регрессионный прогон по расписанию, оповещение при падении метрик ниже порогов MVP
Полная стоимость владения на запрос	Не более 11 руб при 30 000 запросов в месяц
Текущие расходы на запрос	Не более 4 руб при 30 000 запросов в месяц
Система передана в поддержку	Руководство по эксплуатации, обучение проведено

Показателей стоимости два, и считаются они по-разному. Полная стоимость владения делит все затраты за три года, включая разработку и оборудование, на число запросов за тот же срок: она отвечает на вопрос, во что обошёлся проект. Текущие расходы делят только ежемесячные платежи на месячный объём: они отвечают, во что обходится эксплуатация после запуска.

Затраты сопоставлены с ожидаемой выгодой в отдельном расчёте: экономия времени контакт-центра и контент-менеджеров плюс снижение возвратов дают порядка 614 000 руб в месяц, вложения возвращаются за 13-14 месяцев после запуска (быстрее на аренде, медленнее на своём железе), ROI за три года эксплуатации - от 56 до 95 процентов. Порог безубыточности - 51 процент базовой гипотезы; он добавлен критерием Decision Gate, чтобы не строить систему, эффект которой не подтвердился.

Оба порога намеренно заданы выше отраслевого ориентира 0.40 руб. Ориентир считается по текущим расходам, а при объёме порядка 30 000 запросов в месяц затраты определяются постоянной частью, а не токенами. Ориентир становится достижимым

при 275 000 запросов в месяц и улучшается сам по себе с ростом нагрузки, без изменений в архитектуре.

Документы проекта

Репозиторий проекта: https://github.com/SandalAndrey/otus_ai_architect

Полные версии документов, из которых собран настоящий:

- Бизнес-функциональные требования
- План обеспечения данными и полный опросник
- Обоснование модели контракта
- План работ
- Реестр рисков
- Смета этапа разработки
- Сайзинг и стоимость владения
- Экономический эффект и окупаемость
- Трассировка: вопрос - риск - требование - работа - приёмка
- Реестр архитектурных решений