

Фиксация архитектурного решения о хостинге LLM и подготовка к защите

Платформа товарных знаний на базе мультимодального GraphRAG

Домашнее задание 4. Курс OTUS “ИИ-архитектор”

Содержание

Контекст	1
1. Анализ вариантов размещения	2
1.1. Что известно до сравнения	2
1.2. Сравнение по пяти критериям	2
1.3. Что показало сравнение, чего мы не ожидали	3
2. Решение	3
2.1. Честные минусы принятого решения	4
2.2. Раздел “Соответствие и этика”	4
3. Питч для СТО	4
4. Что изменилось в проекте по ходу работы	5
4.1. Найдено противоречие в требованиях	5
4.2. Найден пробел: поведение при отказах нигде не задано	5
4.3. Найдено: бюджет в 5 секунд не следовал из собственных чисел	6
5. Подготовка к защите	7
Итог	8

Контекст

Репозиторий проекта: https://github.com/SandalAndrey/otus_ai_architect

Заказчик - интернет-магазин коллекционных масштабных моделей: более 15 000 позиций в наличии, около 400 автомобильных марок, порядка 600 производителей.

Реестр архитектурных решений ведётся в проекте с самого начала, записей восемь. Настоящая работа добавляет две и правит требования, в которых при подготовке к защите нашлись три противоречия.

Отправная точка неудобная и её стоит назвать сразу. Способ размещения модели в проекте уже был выбран - но не как решение, а как ограничение: в БФТ записано

“обращения к внешним LLM-API исключены архитектурно”, и дальше это повторялось как данность. Ограничение, не проверенное расчётом, на защите неотличимо от предрассудка. Поэтому работа начинается не с оформления готового вывода, а с попытки его опровергнуть.

1. Анализ вариантов размещения

1.1. Что известно до сравнения

- **Классификация данных** (БФТ, раздел 2.1). Гриф Confidential - закупочные цены, маржинальность, договоры с поставщиками, персональные данные.
- **Объём** - 30 000 запросов в месяц. Гипотеза, подтверждается вопросом Q-19.
- **Расход токенов** - замер на прототипе: от четырёх до шести вызовов модели на запрос, вход в среднем около 600 токенов, выход около 150. Итого порядка 3750 токенов на запрос и 112 млн токенов в месяц.
- **Замер на CPU-профиле** - полный ответ 49-68 с при бюджете 5 с.
- **Расчёт видеопамати** - модель 30B в INT4 с KV-cache на 20 потоков генерации занимает 29.1 ГБ и помещается в карту 40 ГБ.

1.2. Сравнение по пяти критериям

Критерий	B0. Внешний LLM-API	B1. Аренда GPU в РФ-облаке	B2. Свой сервер on-premise	B3. CPU-only
ТСО за 3 года	7.96-12.42 млн руб	13.73 млн руб	11.01 млн руб	6.71 млн руб
Текущие расходы на запрос	3.67-7.80 руб	8.50 руб	3.67 руб	1.77 руб
Безопасность данных	Гриф Confidential покидает контур	Контур наш, железо арендованное	Данные не покидают периметр	Данные не покидают периметр
Качество ответов	Выше: закрытые модели старших тарифов сильнее открытых 8-30B	Потолок открытой модели	Тот же потолок	Тот же потолок
Latency	0.3-1.0 с на вызов, плюс сеть и чужие квоты	4.6-4.8 с по расчёту бюджета токенов, запаса нет	То же	49-68 с. Замер

Критерий	B0. Внешний LLM-API	B1. Аренда GPU в РФ-облаке	B2. Свой сервер on-premise	B3. CPU-only
Сложность поддержки	Низкая: инференс не наш	Средняя: инференс наш, железо чужое	Высокая: плюс закупка и замена карты	Средняя

Вилка стоимости B0 - это два тарифных уровня российских провайдеров: 0.40 руб за 1000 токенов на облегчённой модели и 1.50 руб на модели среднего уровня. Разработка для B0 оценена в 1100 часов вместо 1300: отпадают подбор квантования, сайзинг видеопамати и развёртывание инференса.

1.3. Что показало сравнение, чего мы не ожидали

Внешний API не даёт решающей экономии на нашем объёме. На облегчённом тарифе он дешевле покупки сервера на 3 млн за три года, на тарифе, сопоставимом по качеству с задачей, - уже дороже на 1.4 млн. Причина в том, что при 30 000 запросов в месяц затраты любого варианта определяются постоянной частью, а не токенами.

Это меняет характер решения. Ожидалось, что закрытый контур придётся защищать от аргумента “в облаке дешевле”. Оказалось, что защищать надо другое: отказ от внешнего API покупается не деньгами, а качеством ответов и сложностью поддержки. Аргументация на защите строится вокруг этого, а не вокруг стоимости.

Про 152-ФЗ надо говорить точно. Российские провайдеры LLM-API обрабатывают данные на территории РФ, и сам по себе закон их не запрещает. Блокирует другое: передача третьему лицу закупочных цен и текстов договоров - это раскрытие коммерческой тайны, режим которой Заказчик поддерживает отдельно от режима ПДн. Аргумент “нельзя по 152-ФЗ” был бы неверным, и на защите его использовать нельзя.

Гибрид отклонён по проверяемости, а не по сложности. Схема “внешний API для грифа Public, свой контур для остального” выглядит разумно, но класс данных определяется по результату извлечения, а маршрут вызова модели - до него. Пришлось бы гарантировать, что ни один фрагмент выше Public не попал в промпт, уходящий наружу, и доказать это на приёмке нечем.

2. Решение

Языковая модель размещается в контуре, управляемом Исполнителем и Заказчиком, на арендованном GPU российского провайдера. Веса открытые, разворачиваются нами. Обращения к внешним LLM-API отсутствуют архитектурно: на диаграмме уровня 2 сервис инференса находится внутри границы платформы, исходящих связей за периметр у него нет.

Три уточнения, без которых решение неполно:

1. **Аренда - на этап 1.** Покупка окупается против аренды за 17 месяцев, но до подтверждения фактической нагрузки это преждевременное обязательство на

2.5 млн руб. Пересмотр - после трёх месяцев эксплуатации.

2. **Провайдер выбирается с возможностью выезда.** Стандартный OpenAI-совместимый протокол на границе сервиса инференса, никаких проприетарных расширений в промптах.
3. **CPU-only не рассматривается как режим эксплуатации.** Основание - замер, а не оценка.

Полный текст: ADR-0009.

2.1. Честные минусы принятого решения

Раздел вынесен отдельно, потому что он и есть содержательная часть ADR.

- **Качество ниже.** Открытая модель 8-30B слабее старших закрытых на рассуждении и длинном контексте. Первым это проявится на многошаговых вопросах - том самом классе, ради которого выбран GraphRAG. Компенсация не в модели, а в схеме: обход графа сужает контекст, верификатор ловит вымысел.
- **MLOps становится нашим.** Развёртывание, квантование, наблюдаемость, обновление весов, дежурство - работы, которых при внешнем API нет вообще. В смету заложены, в компетенции команды - нет.
- **Одна карта - одна точка отказа.** Резервной не заложено сознательно: вторая карта удваивает основную статью расходов ради сценария, вероятность которого не оценена.
- **Аренда дороже покупки.** 13.73 млн против 11.01 млн за три года. Мы платим 2.7 млн за право не принимать решение сейчас. Это покупка опциона, а не экономия.
- **Запаса по видеопамяти немного.** При нагрузке выше 2 RPS первым упрётся KV-cache, и следующий шаг - карта на 80 ГБ, а не настройка.

2.2. Раздел “Соответствие и этика”

Для решений, влияющих на поведение модели, в шаблон ADR добавлен обязательный раздел: галлюцинации, смещение выборки, инъекции и токсичность, персональные данные, лицензии на веса, объяснимость. Правило - на каждый пункт ответ в виде требования или элемента диаграммы.

Заполнение раздела дало новое требование, которого в проекте не было. **NFR-2.6, справедливость подбора.** Каталог представлен неравномерно: у массовых марок описаний и упоминаний в разы больше, чем у редких. При подборе аналога это систематически смещает выдачу к популярным позициям, причём тихо: ответ выглядит правдоподобно, а часть подходящих моделей просто не находится. Порог - полнота на редких марках не ниже 0.80 от полноты на массовых.

Объяснимость отдельной метрикой не выносится: она уже измеряется через NFR-2.4, где ответ без ссылки на источник считается несоответствующим независимо от того, верен он по существу.

3. Питч для СТО

Мы строим ассистента по товарным знаниям для магазина с 15 000 позиций, где ключевая ценность - не текст описаний, а связи между артикулом,

прототипом и пресс-формой: одна форма выходит под тремя брендами, и вопрос “что ещё выпускалось по этому прототипу” не решается поиском по описанию ни при каком его качестве. В том же хранилище лежат закупочные цены и договоры, поэтому модель размещается в нашем контуре, а не за его границей. Считаю нужным сказать прямо: экономикой это решение не оправдано - на нашем объёме внешний API стоит примерно столько же, а по качеству ответов он лучше, и мы этой разницей платим. Оправдано оно тем, что отсутствие утечки грифа Confidential у нас - блокирующий критерий приёмки, а не пожелание, и доказывается оно отсутствием исходящих связей на диаграмме, а не процедурой и не доверием к провайдеру. Заменить это доказательство на договор с третьим лицом мы не можем, а всё остальное - качество, стоимость, сложность поддержки - предмет инженерной работы, которая уже спланирована.

Формулировка “единственно верное решение” в питче сознательно не используется. Решение верное в текущих условиях; условие названо явно - режим коммерческой тайны у Заказчика. Изменится условие - изменится решение, и в записи есть раздел о том, что при этом придётся переделать.

4. Что изменилось в проекте по ходу работы

4.1. Найдено противоречие в требованиях

Подготовка к вопросу “что будет при тысяче одновременных пользователей” вскрыла несогласованность, прожившую в документе три версии. Требования задавали одновременно: пропускную способность от 5 RPS, время ответа до 5 с и 20 одновременных сессий.

Эти три числа несовместимы. По закону Литтла одновременных обработок = пропускная способность $\times$ время ответа, то есть 5 RPS при пятисекундном ответе дают 25 запросов в системе, а с параллельным запуском агентов извлечения - до 50 потоков генерации. По расчёту KV-cache это 40.4 ГБ вместе с весами: не помещается в карту 40 ГБ вообще ничего.

Устранено снижением требования, а не покупкой железа. При подтверждаемом объёме в 30 000 запросов в месяц среднее - 0.012 RPS, и даже двадцатикратный пик даёт 0.23 RPS. Требование в 2 RPS сохраняет восьмикратный запас. Пересчитано: 10 одновременных обработок, до 20 потоков генерации, 29.1 ГБ вместе с весами. Добавлено отдельное требование на число активных диалогов, потому что диалог и запрос в обработке - разные вещи, и смешивать их было ошибкой.

4.2. Найден пробел: поведение при отказах нигде не задано

Лайфхак из материалов занятия - требовать показать пальцем на диаграмме, где именно срабатывает повтор, а где размыкатель цепи. На этот вопрос в проекте не было ответа. Доступность задана числом, состав агентов описан, а поведение при отказе соседа не зафиксировано нигде.

Пробел опаснее, чем кажется: без явного правила таймаут окажется значением по умолчанию библиотеки, то есть 30-60 секунд или бесконечность. При бюджете

в 5 с один такой вызов занимает поток генерации, и при десяти одновременных обработках очередь встаёт целиком.

Закрывается записью ADR-0010: пофазные таймауты с привязкой к компонентам уровня 3, повторы только на идемпотентных вызовах, размыкатель цепи на двух границах, три различных для пользователя уровня деградации.

Одно последствие записано как принятое, а не как решённое: при таймауте верификатора ответ уходит пользователю с пометкой “не проверено”. Это противоречит духу требования об обязательной ссылке на источник, и мы это допускаем осознанно - верификатор самый дорогой участник схемы и самый вероятный источник таймаута. Порог доли непроверенных ответов задаётся на нагрузочном тестировании.

4.3. Найдено: бюджет в 5 секунд не следовал из собственных чисел

Третье противоречие нашлось при проверке уже готовой работы, и оно арифметическое. В документах одновременно стояли: от четырёх до шести последовательных вызовов модели, около 150 выходных токенов на вызов по замеру прототипа, нижняя граница скорости потока в профиле В - 40 токенов/с, и бюджет латентности 5 с.

Простой счёт: 4 вызова x 150 токенов / 40 токенов в секунду = 15 секунд. Утверждение “на арендованном GPU расчётно укладываемся в 5 с” из этих чисел не следовало. Извлечение, guardrails и подготовка промпта в эти 15 с ещё не входили.

Разбор показал, что не хватало одной сущности - лимита вывода на роль. Замер на прототипе её же и подсказывал: верификатор на Qwen3-4B выдал 361 токен против 50 у Qwen3-8B на одинаковом задании, потому что просьбу “отвечать кратко” в промпте модель игнорирует. Средние 150 токенов - это измерение схемы без ограничений, а не проектное значение.

Роль	Лимит вывода	Класс А	Класс В
Супервизор	32	32	32
Агент векторного поиска	48	48	48, параллельно с обходом графа
Агент обхода графа	64	-	64
Составитель ответа	200	200	200
Верификатор	64	64	64
Последовательно		344	360

При 40 токенах/с это 8.6 и 9.0 с - требование не выполняется. При 90 токенах/с - 3.8 и 4.0 с, плюс подготовка промпта 0.3 с и извлечение 0.5 с, итого 4.6 и 4.8 с.

Отсюда два изменения: лимиты вывода задаются параметром генерации на каждую роль, а нижняя граница скорости потока в профиле В поднята с 40 до 90 токенов/с при 20 потоках. Оба записаны в ADR-0010 и в БФТ.

Признаём прямо: запас составил 0.2-0.4 с, то есть его нет. Требование остаётся проектной гипотезой до нагрузочного теста. Если 90 токенов/с при 20 потоках не подтвердятся, NFR-1.2 ослабляется до 8 с по процедуре пересмотра объёма, и выбор между ослаблением требования и более сильным железом выносится Заказчику, а не принимается молча.

Отдельно стоит отметить, откуда взялось противоречие. Число 150 токенов на вызов появилось в расчёте стоимости внешнего API, где важна была сумма токенов за месяц, и там оно корректно. Ошибкой было перенести измеренное среднее в расчёт латентности, где нужно проектное ограничение, а не наблюдение.

5. Подготовка к защите

Заметки к защите переработаны в пять частей: 09-defense-notes.md.

Питч на пять минут построен по схеме контекст - ограничения - ключевая ставка - риски. Ставка формулируется одной фразой: извлекать факты обходом графа знаний, а не только векторным поиском, и применять права доступа в самом запросе к хранилищу, а не постобработкой ответа. Инструменты в питч не входят: на вопрос “почему Neo4j” бесполезно отвечать до того, как слушатель понял задачу про пресс-формы.

Атака сценариями. Пять сценариев, на каждый - имя компонента, а не описание намерения:

Сценарий	Ответ
Упало векторное хранилище	Ветка отваливается по таймауту в vectorAgent, ответ строится на обходе графа. Обе пусты - отказ, а не догадка
Учётная система отвечает 30 с	Размыкатель на связи api -> егр, ответ с пометкой “наличие не подтверждено”. Молчаливая подстановка вчерашнего остатка запрещена
Тысяча пользователей одновременно	Не обслужим и притворяться не будем: сверх десяти обработок отдаётся 429 с Retry-After. Что нужно для обслуживания - карта на 80 ГБ, то есть деньги, а не настройка
Добавить Telegram	Адаптер. Ядро принимает запрос и список разрешённых грифов, а не роль; разбор роли остаётся в шлюзе
Недоступен сервис инференса	Размыкатель на inferenceClient, деградация до обычного поиска по каталогу (NFR-6). Магазин работает как сегодня

Модель угроз STRIDE. Шесть строк, на каждую - ответ в архитектуре. Два пункта закрыты не полностью, и на защите они называются первыми: механизм передачи роли с сайта (риск R-04) и ограничение частоты запросов на пользователя. Второй - настоящий пробел в требованиях, а не отложенная работа.

Карта “куда показывать пальцем” - таблица соответствия десяти типовых вопросов элементам диаграмм уровней 2 и 3.

Итог

Что сделано	Где
ADR-0009: размещение модели, пять критериев, честные минусы, раздел о соответствии и этике	docs/adr/0009-...
ADR-0010: таймауты, повторы, размыкатели, уровни деградации	docs/adr/0010-...
Раздел “Соответствие и этика” в шаблоне ADR и в записях 0004, 0007	docs/adr/
NFR-2.6 о справедливости подбора аналогов	БФТ, раздел 4.2
Согласование NFR-1 по закону Литтла, пересчёт видеопамати	БФТ раздел 4.1, документ сайзинга раздел 2
Лимиты вывода на роль, подъём скорости потока в профиле B с 40 до 90 токенов/с	БФТ раздел 4.1, docs/adr/0010-...
Питч, атака сценариями, STRIDE, карта диаграмм	docs/09-defense-notes.md

Два вывода, ради которых работа делалась.

Первый: ограничение, записанное без расчёта, вредит даже когда оно верное. Правильный ответ “закрытый контур” три версии документа держался на неверном основании - на предполагаемой дороговизне облака и на неточной ссылке на 152-ФЗ. Расчёт вывод не изменил, но заменил аргументацию на ту, которая выдерживает возражение.

Второй: вопросы к защите полезнее готовить до того, как их задаст кто-то другой. Три самых существенных изменения в проекте - согласование требований по закону Литтла, появление записи о поведении при отказах и бюджет токенов с лимитами вывода - возникли не из ревью документации, а из попытки честно ответить на вопросы формата ATAM и пересчитать за собой то, что уже казалось написанным.

Общее у всех трёх одно: противоречие жило в документе не потому, что его никто не читал, а потому, что каждое из чисел по отдельности было верным. Расходились они только при совместной проверке - законом Литтла, делением токенов на скорость потока, поиском ссылки на требование по его номеру.