# Сайзинг инфраструктуры и стоимость инференса

Платформа товарных знаний на базе мультимодального GraphRAG

Домашнее задание 7. Курс OTUS “ИИ-архитектор”

## Содержание


**Контекст** **1**

**1. Исходные данные** **2**

**2. Расчёт видеопамяти** **2**
2.1. Веса . . . . . 2
2.2. KV-cache . . . . . 2
2.3. Итого . . . . . 3

**3. Второй вопрос: а какую скорость это даёт** **3**
3.1. Что проходит, а что нет . . . . . 3

**4. Стоимость аренды в двух облаках** **4**

**5. Оптимизация** **5**
5.1. Continuous batching - это не оптимизация . . . . . 5
5.2. PagedAttention - экономия памяти . . . . . 5
5.3. Квантование работает дважды . . . . . 5

**6. Вывод и рекомендация** **6**


## Контекст

Репозиторий проекта: https://github.com/SandalAndrey/otus_ai_architect

**Таблица с расчётами:** `homework/assets/07-sizing-calculations.xlsx` - пять листов с живыми формулами: исходные данные, видеопамять, подбор карт, стоимость облаков, эффект оптимизаций. Меняется цена или нагрузка - пересчитывается всё остальное.

**Заказчик** - интернет-магазин коллекционных масштабных моделей: более 15 000 позиций, около 400 автомобильных марок, порядка 600 производителей.

Расчёт видеопамяти в проекте был и раньше. Эта работа добавила к нему второй вопрос, которого не было, и он оказался жёстче первого.

# 1. Исходные данные

Нагрузка не выбирается произвольно, она следует из требований.

| Параметр | Значение | Откуда |
|---|---|---|
| Запросов в месяц | 30 000 | Гипотеза проекта, подтверждается вопросом к Заказчику |
| Пропускная способность | 2 RPS | NFR-1.3 |
| Латентность p95 | 5 с | NFR-1.2 |
| Одновременных обработок | 10 | Закон Литтла: 2 RPS x 5 с |
| Потоков генерации | 20 | Агенты извлечения работают параллельно, до двух потоков на запрос |
| Требуемая скорость | 90 ток/с на поток | Выведено из бюджета токенов в ADR-0010 |
| Контекст | 8192 токена | Допущение проекта |

Последняя строка - ключевая, и к ней вернёмся: именно она отсеет большинство конфигураций.

# 2. Расчёт видеопамяти

## 2.1. Веса

`VRAM = параметры x байт на параметр x 1.2`, где 1.2 - накладные расходы на ядра и буферы. Байт на параметр: FP16 - 2.0, INT8 - 1.0, INT4 - 0.6 (0.5 плюс метаданные квантования).

| Модель | FP16, ГБ | INT8, ГБ | INT4, ГБ | Экономия INT4 против FP16 |
|---|---|---|---|---|
| Qwen3-8B | 19.2 | 9.6 | 5.8 | 70 % |
| Qwen3-14B | 33.6 | 16.8 | 10.1 | 70 % |
| Qwen3-30B-A3B | 72.0 | 36.0 | 21.6 | 70 % |

## 2.2. KV-cache

`KV = 2 x слои x размерность_kv x длина x потоки x байт`

Размерность KV зависит от схемы внимания: при GQA она меньше скрытой размерности во столько раз, во сколько KV-голов меньше голов внимания. Для 48 слоёв, скрытой размерности 4096, контекста 8192 и GQA 4/32:

| Точность KV | На поток, ГБ | На 20 потоков, ГБ |
|---|---|---|
| INT8 | 0.375 | 7.5 |

| Точность KV | На поток, ГБ | На 20 потоков, ГБ |
|---|---|---|
| FP16 | 0.750 | 15.0 |

Принято INT8. Без квантования KV занимает больше, чем сама модель 14B.

### 2.3. Итого

| Модель | FP16 + KV, ГБ | INT4 + KV, ГБ |
|---|---|---|
| Qwen3-8B | 26.7 | 13.3 |
| Qwen3-14B | 41.1 | 17.6 |
| Qwen3-30B-A3B | 79.5 | 29.1 |

По памяти в A100 40 ГБ проходят все три модели в INT4 и только 8B в FP16.

## 3. Второй вопрос: а какую скорость это даёт

Здесь работа и перестала быть повторением того, что уже посчитано.

Таблицы выше отвечают, помещается ли модель, и молчат о том, как быстро она будет работать. Механика такая: **генерация каждого токена требует одного прохода по всем весам модели**. Значит скорость упирается не в вычислительную мощность карты, а в полосу её памяти:

```
токенов в секунду = полоса памяти / размер весов x КПД
```

КПД - практически достижимая доля паспортной полосы, принято 0.70.

| Карта | VRAM, ГБ | Полоса, ГБ/с | Тип памяти |
|---|---|---|---|
| T4 | 16 | 320 | GDDR6 |
| L4 | 24 | 300 | GDDR6 |
| A100 | 40 | 1555 | HBM2 |
| A100 | 80 | 1935 | HBM2e |

Разница между A100 и младшими картами - не в объёме, а в типе памяти: полоса отличается впятеро.

### 3.1. Что проходит, а что нет

| Карта | Модель, INT4 | С KV, ГБ | Влезает | ток/с | Вердикт |
|---|---|---|---|---|---|
| T4 16 ГБ | Qwen3-8B | 13.3 | да | 39 | мало скорости |
| T4 16 ГБ | Qwen3-14B | 17.6 | нет | - | не влезает |
| L4 24 ГБ | Qwen3-8B | 13.3 | да | 36 | мало скорости |
| L4 24 ГБ | Qwen3-14B | 17.6 | да | 21 | мало скорости |
| A100 40 ГБ | Qwen3-8B | 13.3 | да | 189 | **подходит** |

| Карта | Модель, INT4 | С KV, ГБ | Влезает | ток/с | Вердикт |
|---|---|---|---|---|---|
| A100 40 ГБ | Qwen3-14B | 17.6 | да | 108 | **подходит** |
| A100 40 ГБ | Qwen3-30B | 29.1 | да | 50 | мало скорости |
| A100 80 ГБ | Qwen3-30B | 29.1 | да | 63 | мало скорости |

Два вывода, и оба неочевидны, пока не посчитаешь.

**T4 и L4 отпадают не по памяти, а по скорости.** Модель 8B в INT4 помещается в обе, остаётся 3-11 ГБ свободных, и по цене они выглядят разумной альтернативой. Но дают 36-39 токенов в секунду вместо 90. Набрать скорость числом карт не получится: тензорный параллелизм делит веса между картами и тем увеличивает эффективную полосу, но добавляет обмен между картами на каждом проходе, а проходов столько же, сколько токенов.

**Модель 30B не проходит ни на одной доступной карте.** В A100 40 ГБ она помещается с запасом в 11 ГБ и выдаёт 50 ток/с. На A100 80 ГБ полоса выше, но веса те же, и получается 63 - всё равно мало при вдвое большей цене.

Это прямо затронуло наш проект: в требованиях профиль B был описан как “модель 14-30B в INT4”, и верхняя половина диапазона оказалась непригодной. Требование исправлено, обоснование вынесено в ADR-0019.

## 4. Стоимость аренды в двух облаках

Цены собраны в октябре 2026 и перед договором подлежат перепроверке.

| Провайдер | Конфигурация | Руб/ч | Круглосуточно, руб/мес | 12 ч в сутки, руб |
|---|---|---|---|---|
| Yandex Cloud | A100 40 ГБ, нижняя ставка | 179 | 130 700 | 65 300 |
| Yandex Cloud | A100 40 ГБ, верхняя ставка | 223 | 162 800 | 81 400 |
| Yandex Cloud | T4 16 ГБ, DataSphere | 168.48 | 123 000 | 61 500 |
| Cloud.ru | A100 vGPU 40 ГБ | 252.85 | 184 600 | 92 300 |
| Cloud.ru | A100 vGPU 80 ГБ | 313.01 | 228 500 | 114 200 |

**Сопоставимость неполная, и это надо оговаривать.** Yandex тарифицирует карту, процессор и память раздельно - в таблице только карта. Cloud.ru отдаёт vGPU в составе готовой конфигурации. Если добавить к карте Yandex хост с процессором и памятью, получится около 178 000 руб в месяц против 184 600 у Cloud.ru, то есть разница в пределах нескольких процентов.

Колонка “12 часов в сутки” приведена не зря: публичный контур по NFR-6 обслуживается с 10:00 до 22:00. Но гасить карту на ночь нельзя - внутренний контур работает круглосуточно, а холодный старт модели занимает десятки секунд. Колонка показывает, сколько можно было бы сэкономить, если от внутреннего контура ночью отказаться; это решение Заказчика, а не наше.

**Отдельная находка.** В смете проекта строка “вычислительные ресурсы” для варианта с арендой стояла как 180 000 руб в месяц - записанная до всякой проверки и без источника. Диапазон по двум облакам оказался 178-185 тысяч, то есть цифра лежит внутри него, ближе к верхней границе. Она угадана, а не посчитана, и

оставлена как консервативная: занизить стоимость в смете хуже, чем завысить. Пересчитывать TCO не из чего - разница укладывается в округление.

# 5. Оптимизация

## 5.1. Continuous batching - это не оптимизация

Расчёт скорости в разделе 3 молча предполагал пакетную обработку: за один проход по весам каждый из 20 потоков получает по токену. Посмотрим, что будет без неё.

| Показатель | Без батчинга | С continuous batching |
|---|---|---|
| Требуется суммарно | 1 800 ток/с | 1 800 ток/с |
| Даёт одна A100 40 ГБ | 108 ток/с | 2 160 ток/с |
| Карт нужно | 17 | 1 |
| Аренда, руб/мес | 3 137 900 | 184 600 |

**Экономия - 2.95 млн руб в месяц, в 17 раз.** Но называть это экономией неправильно. Без непрерывной пакетной обработки конфигурация из одной карты просто не работает, а семнадцать карт никто не арендует. Поэтому vLLM или равноценный сервер инференса входит в обязательные требования к реализации, а не в список желательных улучшений.

Разница в природе: без батчинга запросы обрабатываются по очереди, и веса перечитываются из памяти для каждого. С батчингом один проход обслуживает всех, кто сейчас в работе.

## 5.2. PagedAttention - экономия памяти

Классический аллокатор резервирует под каждый поток память на предельную длину контекста заранее. PagedAttention выделяет её страницами по факту.

| Показатель | Классический | PagedAttention |
|---|---|---|
| KV на 20 потоков | 7.5 ГБ | 2.6 ГБ |
| Итого с весами 14B в INT4 | 17.6 ГБ | 12.7 ГБ |

Допущение: средний диалог занимает около трети предельного контекста. Экономия 5 ГБ на карте, где и так свободно 22, сейчас не критична. Она станет важной при росте контекста или числа потоков.

## 5.3. Квантование работает дважды

Этот эффект стоит назвать отдельно, потому что в задании он сформулирован как “снижение памяти, значит более дешёвые GPU”, и для нашего случая это верно лишь наполовину.

Переход с FP16 на INT4 уменьшает веса в 3.3 раза. Первое следствие очевидно: модель помещается в меньшую карту. Второе - **она генерирует быстрее**, потому что за

каждый проход читается втрое меньше байт. Для 14B это 32 ток/с в FP16 против 108 в INT4 на одной и той же A100.

Сжатие KV-cache до INT8 экономит только объём: на скорость генерации оно влияет слабо, потому что KV читается не целиком, а по мере роста контекста.

А вот обещание “более дешёвые GPU” у нас не сработало. Квантование освободило память, но не полосу: T4 и L4 с моделью 8B в INT4 остались медленными. Дешёвая карта стала возможной по памяти и не стала возможной по скорости.

## 6. Вывод и рекомендация

**Рекомендуемая конфигурация: одна NVIDIA A100 40 ГБ, модель Qwen3-14B в INT4, сервер инференса vLLM с непрерывной пакетной обработкой.**

| Параметр | Значение | Запас |
|---|---|---|
| Веса | 10.1 ГБ | - |
| KV-cache, 20 потоков, INT8 | 7.5 ГБ | - |
| Занято | 17.6 из 40 ГБ | 56 % свободно |
| Скорость на поток | 108 ток/с | 20 % сверх требуемых 90 |
| Стоимость | 178-185 тыс. руб/мес | Yandex Cloud либо Cloud.ru |

Свободные 22 ГБ не излишек: на карте живут ещё эмбеддер и переранжировщик (около 2.8 ГБ), а при переиндексации на время переключения существуют две коллекции сразу.

Провайдер: **Yandex Cloud** как основной вариант - дешевле на несколько процентов и позволяет набрать конфигурацию покомпонентно. Cloud.ru как запасной: готовая конфигурация проще в заказе, но минимальный период аренды составляет месяц, что лишает гибкости на этапе отладки.

**Чего этот расчёт не доказывает.** КПД полосы 0.70 - принятая величина, а не замер; фактическая скорость зависит от реализации сервера инференса и размера батча. Если на нагрузочном тестировании КПД окажется ниже 0.6, модель 14B тоже перестанет проходить, и останется 8B. Само требование 90 ток/с тоже выведено расчётом, а не измерено. Два расчёта опираются друг на друга, и замера под ними пока нет ни одного - это главное ограничение всей работы.

**Что эта работа изменила в проекте.** Расчёт видеопамяти существовал с самого начала и отвечал на вопрос “поместится ли”. Вопрос “а с какой скоростью” не ставился, и из-за этого в требованиях три месяца стояла модель, которая физически не может выдать нужную скорость на выбранном железе. Нашлось это не при ревью документов, а при попытке посчитать то, что раньше считали очевидным.