Сайзинг инфраструктуры и стоимость инференса

Платформа товарных знаний на базе мультимодального GraphRAG

Домашнее задание 7. Курс OTUS “ИИ-архитектор”

Содержание

Контекст **1**

1. Исходные данные **2**

2. Расчёт видеопамяти **2**
2.1. Веса 2
2.2. KV-cache 2
2.3. Итого 3

3. Второй вопрос: а какую скорость это даёт **3**
3.1. Что проходит, а что нет 3

4. Стоимость аренды в двух облаках **4**

5. Оптимизация **5**
5.1. Continuous batching - это не оптимизация 5
5.2. PagedAttention - экономия памяти 5
5.3. Квантование работает дважды 5

6. Вывод и рекомендация **6**

Контекст

Репозиторий проекта: https://github.com/SandalAndrey/otus_ai_architect

Таблица с расчётами: Google Таблица (тот же файл в репозитории: `homework/assets/07-sizing-` - пять листов с живыми формулами: исходные данные, видеопамять, подбор карт, стоимость облаков, эффект оптимизаций. Меняется цена или нагрузка - пересчитывается всё остальное.

Заказчик - интернет-магазин коллекционных масштабных моделей: более 15 000 позиций, около 400 автомобильных марок, порядка 600 производителей.

Расчёт видеопамяти в проекте был и раньше. Эта работа добавила к нему второй вопрос, которого не было, и он оказался жёстче первого.

1. Исходные данные

Нагрузка не выбирается произвольно, она следует из требований.

Параметр	Значение	Откуда
Запросов в месяц	30 000	Гипотеза проекта, подтверждается вопросом к Заказчику
Пропускная способность	2 RPS	NFR-1.3
Латентность p95	5 с	NFR-1.2
Одновременных обработок	10	Закон Литтла: 2 RPS x 5 с
Потоков генерации	20	Агенты извлечения работают параллельно, до двух потоков на запрос
Требуемая скорость	90 ток/с на поток	Выведено из бюджета токенов в ADR-0010
Контекст	8192 токена	Допущение проекта

Последняя строка - ключевая, и к ней вернёмся: именно она отсеет большинство конфигураций.

2. Расчёт видеопамяти

2.1. Веса

`VRAM = параметры x байт на параметр x 1.2`, где 1.2 - накладные расходы на ядра и буферы. Байт на параметр: FP16 - 2.0, INT8 - 1.0, INT4 - 0.6 (0.5 плюс метаданные квантования).

Модель	FP16, ГБ	INT8, ГБ	INT4, ГБ	Экономия INT4 против FP16
Qwen3-8B	19.2	9.6	5.8	70 %
Qwen3-14B	33.6	16.8	10.1	70 %
Qwen3-30B-A3B	72.0	36.0	21.6	70 %

2.2. KV-cache

`KV = 2 x слои x размерность_kv x длина x потоки x байт`

Размерность KV зависит от схемы внимания: при GQA она меньше скрытой размерности во столько раз, во сколько KV-голов меньше голов внимания. Для 48 слоёв, скрытой размерности 4096, контекста 8192 и GQA 4/32:

Точность KV	На поток, ГБ	На 20 потоков, ГБ
INT8	0.375	7.5

Точность KV	На поток, ГБ	На 20 потоков, ГБ
FP16	0.750	15.0

Принято INT8. Без квантования KV занимает больше, чем сама модель 14B.

2.3. Итого

Модель	FP16 + KV, ГБ	INT4 + KV, ГБ
Qwen3-8B	26.7	13.3
Qwen3-14B	41.1	17.6
Qwen3-30B-A3B	79.5	29.1

По памяти в A100 40 ГБ проходят все три модели в INT4 и только 8B в FP16.

3. Второй вопрос: а какую скорость это даёт

Здесь работа и перестала быть повторением того, что уже посчитано.

Таблицы выше отвечают, помещается ли модель, и молчат о том, как быстро она будет работать. Механика такая: **генерация каждого токена требует одного прохода по всем весам модели**. Значит скорость упирается не в вычислительную мощность карты, а в полосу её памяти:

```
токенов в секунду = полоса памяти / размер весов x КПД
```

КПД - практически достижимая доля паспортной полосы, принято 0.70.

Карта	VRAM, ГБ	Полоса, ГБ/с	Тип памяти
T4	16	320	GDDR6
L4	24	300	GDDR6
A100	40	1555	HBM2
A100	80	1935	HBM2e

Разница между A100 и младшими картами - не в объёме, а в типе памяти: полоса отличается впятеро.

3.1. Что проходит, а что нет

Карта	Модель, INT4	С KV, ГБ	Влезает	ток/с	Вердикт
T4 16 ГБ	Qwen3-8B	13.3	да	39	мало скорости
T4 16 ГБ	Qwen3-14B	17.6	нет	-	не влезает
L4 24 ГБ	Qwen3-8B	13.3	да	36	мало скорости
L4 24 ГБ	Qwen3-14B	17.6	да	21	мало скорости
A100 40 ГБ	Qwen3-8B	13.3	да	189	**подходит**

Карта	Модель, INT4	С KV, ГБ	Влезает	ток/с	Вердикт
A100 40 ГБ	Qwen3-14B	17.6	да	108	**подходит**
A100 40 ГБ	Qwen3-30B	29.1	да	50	мало скорости
A100 80 ГБ	Qwen3-30B	29.1	да	63	мало скорости

Два вывода, и оба неочевидны, пока не посчитаешь.

T4 и L4 отпадают не по памяти, а по скорости. Модель 8B в INT4 помещается в обе, остаётся 3-11 ГБ свободных, и по цене они выглядят разумной альтернативой. Но дают 36-39 токенов в секунду вместо 90. Набрать скорость числом карт не получится: тензорный параллелизм делит веса между картами и тем увеличивает эффективную полосу, но добавляет обмен между картами на каждом проходе, а проходов столько же, сколько токенов.

Модель 30B не проходит ни на одной доступной карте. В A100 40 ГБ она помещается с запасом в 11 ГБ и выдаёт 50 ток/с. На A100 80 ГБ полоса выше, но веса те же, и получается 63 - всё равно мало при вдвое большей цене.

Это прямо затронуло наш проект: в требованиях профиль B был описан как “модель 14-30B в INT4”, и верхняя половина диапазона оказалась непригодной. Требование исправлено, обоснование вынесено в ADR-0019.

4. Стоимость аренды в двух облаках

Цены собраны в октябре 2026 и перед договором подлежат перепроверке.

Провайдер	Конфигурация	Руб/ч	Круглосуточно, руб/мес	12 ч в сутки, руб
Yandex Cloud	A100 40 ГБ, нижняя ставка	179	130 700	65 300
Yandex Cloud	A100 40 ГБ, верхняя ставка	223	162 800	81 400
Yandex Cloud	T4 16 ГБ, DataSphere	168.48	123 000	61 500
Cloud.ru	A100 vGPU 40 ГБ	252.85	184 600	92 300
Cloud.ru	A100 vGPU 80 ГБ	313.01	228 500	114 200

Сопоставимость неполная, и это надо оговаривать. Yandex тарифицирует карту, процессор и память раздельно - в таблице только карта. Cloud.ru отдаёт vGPU в составе готовой конфигурации. Если добавить к карте Yandex хост с процессором и памятью, получится около 178 000 руб в месяц против 184 600 у Cloud.ru, то есть разница в пределах нескольких процентов.

Колонка “12 часов в сутки” приведена не зря: публичный контур по NFR-6 обслуживается с 10:00 до 22:00. Но гасить карту на ночь нельзя - внутренний контур работает круглосуточно, а холодный старт модели занимает десятки секунд. Колонка показывает, сколько можно было бы сэкономить, если от внутреннего контура ночью отказаться; это решение Заказчика, а не наше.

Отдельная находка. В смете проекта строка “вычислительные ресурсы” для варианта с арендой стояла как 180 000 руб в месяц - записанная до всякой проверки и без источника. Диапазон по двум облакам оказался 178-185 тысяч, то есть цифра лежит внутри него, ближе к верхней границе. Она угадана, а не посчитана, и

оставлена как консервативная: занизить стоимость в смете хуже, чем завысить. Пересчитывать TCO не из чего - разница укладывается в округление.

5. Оптимизация

5.1. Continuous batching - это не оптимизация

Расчёт скорости в разделе 3 молча предполагал пакетную обработку: за один проход по весам каждый из 20 потоков получает по токену. Посмотрим, что будет без неё.

Показатель	Без батчинга	С continuous batching
Требуется суммарно	1 800 ток/с	1 800 ток/с
Даёт одна A100 40 ГБ	108 ток/с	2 160 ток/с
Карт нужно	17	1
Аренда, руб/мес	3 137 900	184 600

Экономия - 2.95 млн руб в месяц, в 17 раз. Но называть это экономией неправильно. Без непрерывной пакетной обработки конфигурация из одной карты просто не работает, а семнадцать карт никто не арендует. Поэтому vLLM или равноценный сервер инференса входит в обязательные требования к реализации, а не в список желательных улучшений.

Разница в природе: без батчинга запросы обрабатываются по очереди, и веса перечитываются из памяти для каждого. С батчингом один проход обслуживает всех, кто сейчас в работе.

5.2. PagedAttention - экономия памяти

Классический аллокатор резервирует под каждый поток память на предельную длину контекста заранее. PagedAttention выделяет её страницами по факту.

Показатель	Классический	PagedAttention
KV на 20 потоков	7.5 ГБ	2.6 ГБ
Итого с весами 14B в INT4	17.6 ГБ	12.7 ГБ

Допущение: средний диалог занимает около трети предельного контекста. Экономия 5 ГБ на карте, где и так свободно 22, сейчас не критична. Она станет важной при росте контекста или числа потоков.

5.3. Квантование работает дважды

Этот эффект стоит назвать отдельно, потому что в задании он сформулирован как “снижение памяти, значит более дешёвые GPU”, и для нашего случая это верно лишь наполовину.

Переход с FP16 на INT4 уменьшает веса в 3.3 раза. Первое следствие очевидно: модель помещается в меньшую карту. Второе - **она генерирует быстрее**, потому что за

каждый проход читается втрое меньше байт. Для 14B это 32 ток/с в FP16 против 108 в INT4 на одной и той же A100.

Сжатие KV-cache до INT8 экономит только объём: на скорость генерации оно влияет слабо, потому что KV читается не целиком, а по мере роста контекста.

А вот обещание “более дешёвые GPU” у нас не сработало. Квантование освободило память, но не полосу: T4 и L4 с моделью 8B в INT4 остались медленными. Дешёвая карта стала возможной по памяти и не стала возможной по скорости.

6. Вывод и рекомендация

Рекомендуемая конфигурация: одна NVIDIA A100 40 ГБ, модель Qwen3-14B в INT4, сервер инференса vLLM с непрерывной пакетной обработкой.

Параметр	Значение	Запас
Веса	10.1 ГБ	-
KV-cache, 20 потоков, INT8	7.5 ГБ	-
Занято	17.6 из 40 ГБ	56 % свободно
Скорость на поток	108 ток/с	20 % сверх требуемых 90
Стоимость	178-185 тыс. руб/мес	Yandex Cloud либо Cloud.ru

Свободные 22 ГБ не излишек: на карте живут ещё эмбеддер и переранжировщик (около 2.8 ГБ), а при переиндексации на время переключения существуют две коллекции сразу.

Провайдер: **Yandex Cloud** как основной вариант - дешевле на несколько процентов и позволяет набрать конфигурацию покомпонентно. Cloud.ru как запасной: готовая конфигурация проще в заказе, но минимальный период аренды составляет месяц, что лишает гибкости на этапе отладки.

Чего этот расчёт не доказывает. КПД полосы 0.70 - принятая величина, а не замер; фактическая скорость зависит от реализации сервера инференса и размера батча. Если на нагрузочном тестировании КПД окажется ниже 0.6, модель 14B тоже перестанет проходить, и останется 8B. Само требование 90 ток/с тоже выведено расчётом, а не измерено. Два расчёта опираются друг на друга, и замера под ними пока нет ни одного - это главное ограничение всей работы.

Что эта работа изменила в проекте. Расчёт видеопамяти существовал с самого начала и отвечал на вопрос “поместится ли”. Вопрос “а с какой скоростью” не ставился, и из-за этого в требованиях три месяца стояла модель, которая физически не может выдать нужную скорость на выбранном железе. Нашлось это не при ревью документов, а при попытке посчитать то, что раньше считали очевидным.